

Fundamentos de ciencias de sistemas

Iris Dataset

Clasificación con KNN y Árbol de Decisión



150 muestras · 3 clases · 4 características

https://colab.research.google.com/drive/1DgLR_DegxhamkD6aTA9ESqOTFU_A5HAN?usp=sharing



1. Introducción al Machine Learning

¿Qué es el Machine Learning?

- Rama de la inteligencia artificial
- Los modelos aprenden patrones a partir de datos
- No se programan reglas manualmente
- El algoritmo generaliza para predecir casos nuevos
- Usos: diagnóstico médico, recomendaciones, visión por computadora

¿Qué es un problema de clasificación?

- Asignar una etiqueta o categoría a una entrada
- Entrada: características (números, texto, imágenes)
- Salida: clase (ej. 'gato', 'perro', 'setosa')
- El modelo aprende la frontera entre clases
- Ejemplo: dado el tamaño del pétalo → ¿qué flor es?



2. ¿Qué es el Iris Dataset?

150

Muestras totales

3

Clases de flores

4

Características

- Origen: Ronald A. Fisher, estadístico británico (1936)
- Clases: Setosa · Versicolor · Virginica (50 muestras c/u)
- Variables: largo del sépalo, ancho del sépalo, largo del pétalo, ancho del pétalo
- Objetivo: predecir la especie a partir de sus medidas en centímetros
- Considerado el 'Hola Mundo' del Machine Learning




3. Exploración de Datos

¿Por qué usar solo el pétalo?

- El pétalo tiene mayor poder discriminativo
- El sépalo presenta más solapamiento entre clases
- Con 2 variables podemos visualizar en un plano 2D
- Simplifica la comprensión sin perder precisión
- $X = \text{largo del pétalo}$ · $Y = \text{ancho del pétalo}$

¿Qué se observa en la gráfica?

- Setosa: completamente separada del resto
- Versicolor: zona central del gráfico
- Virginica: pétalos más grandes





4. Algoritmos Utilizados

KNN — K Vecinos más Cercanos

- Para clasificar un punto nuevo:
 - 1. Busca los K puntos más cercanos en el espacio
 - 2. Cuenta cuántos pertenecen a cada clase
 - 3. Asigna la clase más frecuente
- $K = 3$ en este experimento
- Sensible a la escala de los datos

Árbol de Decisión

- Aprende reglas tipo SI-ENTONCES
- Ejemplo de regla:
 - $SI\ largo_pétalo \leq 2.45 \rightarrow Setosa$
 - $SI\ largo_pétalo > 2.45\ Y\ ancho_pétalo \leq 1.75 \rightarrow Versicolor$
 - $EN\ OTRO\ CASO \rightarrow Virginica$
- Genera fronteras rectangulares
- Muy interpretable: se puede leer la lógica

5. Explicación del Código Python

`load_iris()`

Carga el dataset completo: 150 filas × 4 columnas + etiquetas de clase

`train_test_split()`

Divide en 70% entrenamiento y 30% prueba.
`random_state=42` garantiza reproducibilidad

`predict()`

Aplica el modelo a los datos de prueba y genera una predicción por muestra

`X e y`

X = características (largo y ancho del pétalo) · y = etiqueta de clase (0, 1, 2)

`fit()`

Entrena el modelo: KNN memoriza los puntos; el Árbol construye las reglas

`accuracy_score()`

Compara predicciones vs. valores reales. Precisión = aciertos / total




6. Visualización de Resultados




Gráfica de Dispersión

- Eje X: largo del pétalo (cm)
- Eje Y: ancho del pétalo (cm)
- Color del punto = especie real
 - Rojo = Setosa · Verde = Versicolor · Azul = Virginica



Regiones de Decisión

- El fondo coloreado muestra qué predice el modelo en cada zona
- Puntos mal clasificados caen en zona de color diferente





7. Comparación de Algoritmos

Criterio	KNN	Árbol de Decisión
Fronteras	Curvas y suaves	Rectangulares (angulares)
Interpretab.	Baja – es una 'caja negra'	Alta – se leen las reglas
Velocidad entren.	Muy rápido (guarda datos)	Rápido (construye árbol)
Precisión	Alta (~97% en Iris)	Alta (~95-97% en Iris)
Sensibilidad	Sensible a escala y ruido	Puede sobreajustarse



En Iris, KNN suele lograr mayor precisión; el Árbol ofrece mayor interpretabilidad.

10. Comparación de Métricas — KNN vs. Árbol de Decisión

KNN Accuracy

97.8%

Macro F1: 0.97

KNN (k=3)

Clase	Prec.	Rec.	F1
Setosa	100%	100%	1.00
Versicolor	100%	92%	0.96
Virginica	93%	100%	0.96

Árbol Accuracy

95.6%

Macro F1: 0.95

Árbol de Decisión

Clase	Prec.	Rec.	F1
Setosa	100%	100%	1.00
Versicolor	100%	85%	0.92
Virginica	87%	100%	0.93

💡 Precisión (Prec.) = de los que predije como X, ¿cuántos son realmente X? | Recall (Rec.) = de los que son X, ¿cuántos detecté? | F1 = promedio armónico

11. Matrices de Confusión — KNN vs. Árbol de Decisión

KNN (k=3)

	Setosa	Versic.	Virgin.
Setosa	19	0	0
Versic.	0	12	1
Virgin.	0	0	13

Accuracy: 97.8%

Árbol de Decisión

	Setosa	Versic.	Virgin.
Setosa	19	0	0
Versic.	0	11	2
Virgin.	0	0	13

Accuracy: 95.6%

Legenda:



Aciertos (diagonal)



Errores (fuera de diagonal)



Cero casos

💡 KNN comete 1 error (Versicolor→Virginica). El Árbol comete 2 errores (2 Versicolor clasificadas como Virginica). Setosa: perfecta en ambos modelos.



8. Relación entre Código y Teoría

Setosa separada

- En el gráfico: grupo rojo aislado en esquina inferior izquierda
- Pétalos muy pequeños (largo < 2.5 cm)
- Ambos modelos la clasifican perfectamente
- Región de decisión: zona uniforme sin confusión

Zona de confusión

- Versicolor y Virginica comparten rango de pétalo similar
- Sus puntos se solapan en la zona central
- Ahí el modelo comete más errores
- KNN muestra fronteras curvas en esa zona

Coincidencia visual

- Las regiones de color del código replican lo visto en la teoría
- Separación limpia a la izquierda = Setosa fácil
- Mezcla de colores en el centro = zona difícil
- Los puntos mal clasificados = errores del modelo

9. Conclusiones

- El Iris Dataset es ideal para aprender clasificación: pequeño, limpio y bien documentado
- Usar solo 2 variables (pétalo) permite visualizar el aprendizaje en 2D
- KNN y Árbol de Decisión producen resultados similares pero con fronteras distintas
- Comparar algoritmos revela ventajas y desventajas según el contexto
- Setosa es linealmente separable; Versicolor y Virginica requieren modelos más sofisticados
- El código Python con scikit-learn permite replicar estos resultados en pocas líneas