

Exploración WEKA con dataset IRIS

Alejandro Gómez Moyano


Ingeniería de Sistemas
Fundamentos de ciencias de sistemas

6 de Mayo de 2026

Dataset IRIS: Distribución de Especies


- 150 instancias en total.
- Clasificación por especies mediante colores.
- Análisis visual de atributos (Sépalo y Pétalo).

Visualización: Gráfica de Barras por Especie



Distribución de atributos separando especies por color.

Visualización: mapa de correlación de las variables



mapa de calor de la correlación de variables

Configuración en Pestaña Classify

- Elección del modelo predictivo.
- Configuración de la división de aprendizaje:
 - Training set (ej. 70 %).
 - Test set (ej. 30 %).
- Evaluación de la distribución de los datos.

- en comparación con otros clasificadores, el Naïve Bayes se considera uno más sencillo, ya que los parámetros son más fáciles de estimar.
- El clasificador Naïve Bayes es un clasificador probabilístico simple que cuenta con muy pocos parámetros, los cuales se utilizan para construir modelos de aprendizaje automático que pueden predecir a una velocidad mayor que otros algoritmos de clasificación.

Resultados de Clasificación: Bayes

Informe de Clasificación para Naive Bayes:

	precision	recall	f1-score	support
Iris-setosa	1.00	1.00	1.00	10
Iris-versicolor	1.00	1.00	1.00	9
Iris-virginica	1.00	1.00	1.00	11
accuracy			1.00	30
macro avg	1.00	1.00	1.00	30
weighted avg	1.00	1.00	1.00	30

Precisión del modelo Naive Bayes: 1.00

Resultados de Clasificación: Random Forest

=== Summary ===

Correctly Classified Instances	150	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0.0032		
Root mean squared error	0.0184		
Relative absolute error	0.72	%	
Root relative squared error	3.9038	%	
Total Number of Instances	150		

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-setosa
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-versicolor
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-virginica
Weighted Avg.	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	

=== Confusion Matrix ===

a	b	c	<-- classified as
50	0	0	a = Iris-setosa
0	50	0	b = Iris-versicolor
0	0	50	c = Iris-virginica

- **Estadístico Kappa (1.0):** Concordancia perfecta entre lo observado y lo esperado.
- **Métricas de error:**
 - Mean absolute error: 0.0032
 - Relative absolute error: 0.72 %
 - Root relative squared error: 3.9083 %

Algoritmo C4.5 (Árbol de Decisión)

- Uso de **Entropía** para asignar características diferenciadoras.
- Los atributos con mayor ganancia de información se ubican en los nodos superiores.
- El valor intrínseco ayuda a la reducción (poda) de ramas.

Visualización del Árbol de Decisión (J48)

=== Summary ===

Correctly Classified Instances	150	100	%
Incorrectly Classified Instances	0	0	%
Kappa statistic	1		
Mean absolute error	0		
Root mean squared error	0		
Relative absolute error	0	%	
Root relative squared error	0	%	
Total Number of Instances	150		


=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-setosa
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-versicolor
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	Iris-virginica
Weighted Avg.	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	

=== Confusion Matrix ===

```
a b c <-- classified as
50 0 0 | a = Iris-setosa
0 50 0 | b = Iris-versicolor
0 0 50 | c = Iris-virginica
```

Reglas creadas



Clustering: Algoritmo SimpleKMeans

- Proceso de agrupación basado en similitudes físicas.
- Útil para datos no etiquetados.
- Comparación entre clases reales y la separación generada por el cluster.

clustering(k-means)

```
kMeans
=====

Number of iterations: 5
Within cluster sum of squared errors: 66.36119725363174

Initial starting points (random):

Cluster 0: 64,6.1,2.9,4.7,1.4,Iris-versicolor
Cluster 1: 98,6.2,2.9,4.3,1.3,Iris-versicolor

Missing values globally replaced with mean/mode

Final cluster centroids:

Attribute          Full Data          Cluster#
                   (150.0)          (51.0)          (99.0)
=====
Id                 75.5              26.1373         100.92
SepalLengthCm      5.8433            5.0039          6.27
SepalWidthCm       3.054             3.398           2.87
PetalLengthCm      3.7587            1.5             4.92
PetalWidthCm       1.1987            0.2588          1.68
Species            Iris-setosa        Iris-setosa      Iris-virginia

Time taken to build model (full training data) : 0 seconds

=== Model and evaluation on training set ===

Clustered Instances

0      51 ( 34%)
1      99 ( 66%)
```

Visualización de Atributos (Visualize)

- Resumen matricial de todas las variables frente a frente.
- Identificación de correlaciones entre largo y ancho de pétalos/sépalos.

Matriz de Dispersión: Dataset IRIS Completo

